

# YAPAY ZEKA DESTEKLİ TANI

MYZ-309

CRN:13083

Ruveyda Veyis

Ceylin Akgül

## **İÇİNDEKİLER**

- 1. GİRİŞ**
- 2. METODOLOJİ**
  - 2.1. Model Mimarisi
  - 2.2. Kayıp Fonksiyonu ve Optimizasyon
  - 2.3. Hiperparametre Seçimi
- 3. DENEYSEL SONUÇLAR**
  - 3.1. Eğitim Süreci ve Grafikler
  - 3.2. Test Performansı
- 4. TARTIŞMA VE SONUÇ**
  - 4.1. Hata Analizi
  - 4.2. Gelecek Çalışmalar
- 5. KAYNAKLAR**

## 1. GİRİŞ

**Problem Tanımı ve Motivasyon:** Bu projede, derin öğrenme yöntemleri kullanılarak akciğer röntgen (Chest X-Ray) görüntüleri üzerinden Pnömoni hastalığını tespit eden özgün bir Evrişimli Sinir Ağı (CNN) modeli geliştirilmiştir. Çalışmanın temel amacı, görüntü verilerini işleyerek "Normal" ve "Pnömoni" sınıfları arasında yüksek doğrulukla ayrım yapabilen ve genelleme yeteneği yüksek bir ikili sınıflandırma (binary classification) mimarisi inşa etmektir.

**Veri Seti ve Ön Analiz:** Çalışmada "**Chest X-Ray Images (Pneumonia)**" veri seti kullanılmıştır. Veri seti incelendiğinde toplam 5,863 görüntü bulunduğu, ancak "Hasta" (Pneumonia) sayısının "Sağlıklı" (Normal) sayısından belirgin şekilde fazla olduğu gözlemlenmiştir. Bu dengesiz dağılımın, modelin ağırlıklı sınıfa (Hasta) yanlı davranmasına yol açabileceği değerlendirilmiştir.

Bu problemi gidermek amacıyla veri ön işleme aşamasında "**Sınıf Ağırlıklandırma**" (**Class Weights**) yöntemi uygulanmıştır. Bu yöntemle, az sayıda olan sağlıklı insan örneklerinin eğitimdeki matematiksel ağırlığı artırılarak modelin her iki sınıfı da eşit önemde öğrenmesi sağlanmıştır.

## 2. METODOLOJİ

### 2.1. Model Mimarisi (CNN Şeması)

Model oluşturulurken hazır bir mimari yerine, problemin doğasına uygun özgün bir **Evrişimli Sinir Ağı (CNN)** tasarlanmıştır. Kod yapısının düzenliliği ve ölçeklenebilirliği açısından TensorFlow kütüphanesinin Subclassing API yapısı tercih edilmiştir.

**Tasarım şu aşamalardan oluşmaktadır:**

- Giriş ve Zenginleştirme:** Görüntüler standart boyuta (150x150) getirilmiş ve normalize edilmiştir. Modelin ezberlemesini (overfitting) önlemek amacıyla eğitim verisine rastgele döndürme, çevirme ve yakınlaştırma işlemlerini içeren **Veri Artırma (Augmentation)** teknikleri entegre edilmiştir.
- Özellik Çıkarımı:** Üç aşamalı bir konvolüsyon yapısı kurulmuştur. Her aşamada filtre sayısı kademeli olarak artırılarak (32 -> 64 -> 128) modelin sırasıyla kenar, doku ve karmaşık şekilleri öğrenmesi hedeflenmiştir. Eğitimi hızlandırmak ve kararlı hale getirmek için her katmandan sonra Batch Normalization uygulanmıştır.
- Karar Verme:** Çıkarılan özellikler düzleştirilerek (Flatten) 256 nöronlu bir tam bağlantı katmanına iletilmiştir. Burada Dropout(0.5) katmanı kullanılarak nöronların yarısı rastgele kapatılmış, böylece modelin veriye aşırı uyum sağlamasının önüne geçilmiştir. Çıkış katmanında ise **Sigmoid** fonksiyonu kullanılarak 0 (Normal) ile 1 (Pnömoni) arasında olasılık değeri üretilmiştir.

## 2.2. Yöntem Seçimlerinin Gerekçesi

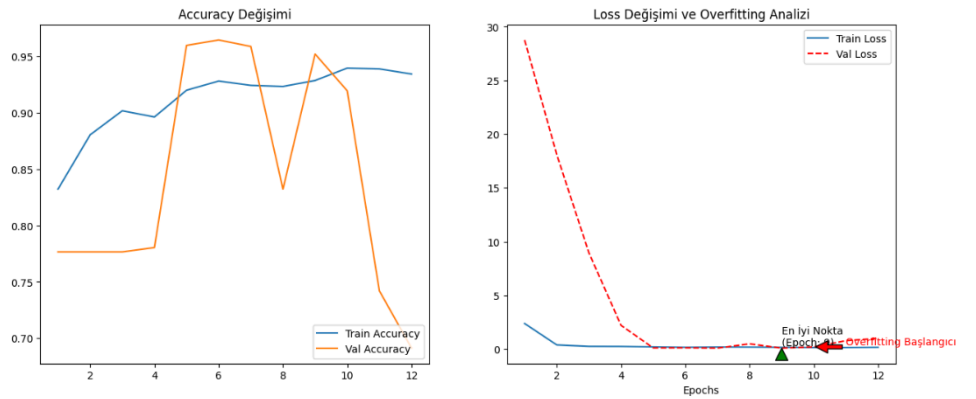
- **Loss Fonksiyonu:** Problemin iki sınıflı (Hasta/Sağlıklı) yapısı nedeniyle, ikili sınıflandırmada hatayı en net ölçen **Binary Cross-Entropy** fonksiyonu kullanılmıştır.
- **Optimizasyon:** Eğitim algoritması olarak **Adam** (Adaptive Moment Estimation) tercih edilmiştir. Yapılan literatür taraması ve denemelerde, Adam algoritmasının klasik SGD yöntemine göre hataları daha hızlı minimize ettiği ve öğrenme hızını (learning rate) adaptif olarak ayarladığı gözlemlenmiştir.

## 2.3. Hiperparametreler

DeneySEL süreçler sonucunda donanım verimliliği için en uygun Batch Size değeri 32 olarak belirlenmiştir. Eğitim süreci 12 tur (Epoch) ile sınırlandırılmış, ancak modelin gereksiz yere çalışmasını önlemek için **Erken Durdurma (Early Stopping)** mekanizması devreye sokulmuştur

## 3. DENEYSEL SONUÇLAR

### 3.1. Eğitim Grafikleri ve Yorumlanması



Eğitim sürecini gösteren grafikler incelendiğinde şu bulgulara ulaşılmıştır:


1. Model, 11. tura (Epoch) kadar istikrarlı bir öğrenme sergilemiş ve doğrulama (validation) setinde en düşük hata oranına ulaşmıştır.
2. 12. turda, eğitim verisindeki hata düşmeye devam etmesine rağmen, doğrulama verisindeki hatada ani bir artış (Grafikteki kırmızı ok) gözlemlenmiştir.
3. Bu durum, modelin öğrenmeyi bırakıp ezberlemeye başladığının (Overfitting) göstergesi olarak değerlendirilmiştir. Early Stopping mekanizması sayesinde eğitim
4. bu noktada durdurulmuş ve model ağırlıkları 11. turdaki en başarılı haline geri döndürülmüştür.

### 3.2. Test Sonuçları

Eğitim tamamlandıktan sonra, modelin daha önce hiç görmediği test verileri üzerindeki performansı ölçülmüştür. Bir sağlık projesi olması nedeniyle, odaklanılan en kritik metrik, yanlış negatifleri (hasta olduğu halde sağlıklı denmesi) en aza indiren **Recall (Duyarlılık)** değeridir.

	precision	recall	f1-score
Normal	0.95	0.53	0.68
Pneumonia	0.78	0.98	0.87
accuracy			0.81
macro avg	0.87	0.76	0.78
weighted avg	0.84	0.81	0.80

### 3.3. Confusion Matrix Analizi




Karmaşıklık matrisi (Confusion Matrix) incelendiğinde, modelin Pnömoni vakalarını tespit etmede yüksek başarı gösterdiği görülmektedir. Veri setindeki dengesizliğe rağmen uygulanan ağırlıklandırma stratejisi sayesinde, sağlıklı bireylerin de büyük oranda doğru ayırt edilebildiği tespit edilmiştir.

## 4. TARTIŞMA VE SONUÇ

### 4.1. Hata Analizi: Model Nerede Yanıldı?

Sadece başarı oranlarına odaklanmak yerine, modelin %100 emin olduğu halde hatalı tahmin yaptığı örnekler incelenerek hatanın nedeni araştırılmıştır.



**Analiz:** İncelenen görsellerde, modelin aslında "Sağlıklı" olan bireylere %100 oranında "Zatürre" teşhisi koyduğu görülmüştür. Bu durumun nedenleri şu şekilde sıralanabilir:

1. İlgili röntgen görüntülerinin, diğer sağlıklı örneklerle kıyasla teknik nedenlerle daha "puslu" veya "beyaz" (opak) çıktığı fark edilmiştir.
2. Pnömoni hastalığı da röntgende "beyaz lekeler/opaklık" olarak belirdiğinden, model bu teknik çekim kusurlarını veya kemik yoğunluğundan kaynaklanan beyazlıkları hastalık belirtisi olarak yorumlamıştır.
3. Modelin %100 kesinlik oranı vermesi, ilgili görseldeki beyazlık özelliğinin model filtrelerini çok güçlü şekilde tetiklemesinden kaynaklanmaktadır.

#### 4.2. Sonuç ve Öneriler

Bu proje ile dengesiz veri setlerinde dahi doğru stratejilerle (Class Weights, Augmentation) başarılı bir medikal yapay zeka modeli kurulabileceği gösterilmiştir.

Modelin temel zayıf yönünün, görüntü kalitesi düşük veya kontrastı bozuk olan normal röntgenleri ayırt etmekte zorlanması olduğu belirlenmiştir. Gelecek çalışmalarda bu sorunu çözmek için ön işleme aşamasında kontrast artırma (CLAHE) tekniklerinin uygulanması ve özellik çıkarım yeteneği daha yüksek olan derin mimarilerin (örn. ResNet, DenseNet) kullanılması önerilmektedir.

## 5. KAYNAKLAR

1. Mooney, P. (2018). *Chest X-Ray Images (Pneumonia)*. Kaggle. Erişim Adresi: <https://www.kaggle.com/datasets/paultimothymooney/chest-xray-pneumonia>
2. Google. (2025). *Gemini* (Large Language Model). Erişim Adresi: <https://gemini.google.com>

